

Ministère de l'Enseignement Supérieur et la Recherche Scientifique

Faculté des Sciences Exactes et Informatique

Département d'Informatique

Tp Module:

NoSQL & Big Data



Réalisé par: Mlle. Guetarni

Qu'est-ce que MapReduce?

- MapReduce est un modèle de programmation qui fonctionne sur Hadoop, un moteur d'analyse de données largement utilisé pour le Big Data. Il permet de créer des applications qui s'exécutent en parallèle pour traiter de grands volumes de données stockées sur des clusters.
- MapReduce est utilisé dans divers secteurs, notamment les services logicielles et informatiques, les services financiers, le secteur de la santé, l'enseignement supérieur, l'assurance, les télécommunications et le secteur bancaire.
- MapReduce est conçu pour réduire la complexité du parallélisme et de la synchronisation en permettant le traitement de problèmes parallélisables à grande échelle sur de nombreux ordinateurs.

Les composants de MapReduce


Le modèle MapReduce est composé de trois opérations principales:

Map: Chaque noeud traite les données d'entrée et les transforme en un ensemble de paires clé/valeur intermédiaire.

Shuffle: Cette phase regroupe les paires clé/valeur par clé, de sorte que toutes les paires avec la même clé soient regroupées ensemble.

Reduce: Dans cette phase, les paires clé/valeur regroupées dans la phase précédente sont traitées pour produire un ensemble de valeurs finales.

MapReduce est souvent utilisé en conjonction avec le framework Hadoop, qui fournit une implémentation de MapReduce ainsi qu'un HDFS pour le stockage des données.



La fonction `map()`:

- La fonction **`map()`** en MapReduce est une étape de programmation MapReduce, utilisé pour le traitement de gros volumes de données.
- La fonction **`map()`** prend en entrée des données sous la forme de paires **`<clé,valeur>`** et les traite pour produire un ensemble de paires **`<clé,valeur>`** intermédiaires en sortie.
- La fonction est appliquée de manière parallèle à chaque paire de données dans l'ensemble d'entrée, ce qui permet un traitement efficace des données sur un grand nombre de noeuds.
- Le résultat intermédiaire produit par la fonction **`map()`** est ensuite comme entrée pour la fonction **`reduce()`**.

La fonction `shuffle()`:


- La fonction **`shuffle()`** est essentielle pour transférer les sorties intermédiaires des mappers vers les reducers, en effectuant un tri des données pour regrouper les clés similaires avant de les envoyer aux reducers.
- Elle permet de garantir que chaque reducer reçoit les données intermédiaires associées à ses clés de manière ordonnée, facilitant ainsi le processus de réduction.
- Le tri des données pendant la phase de shuffle permet d'optimiser les opérations de réduction, en particulier lorsque les données sont distribuées sur plusieurs nœuds du cluster.
- La fonction **`shuffle()`** en MapReduce joue un rôle crucial dans le transfert et le tri des données intermédiaires entre les mappers et les reducers, ce qui contribue à l'efficacité globale du processus de traitement des données.



La fonction **reducer()**:

- La fonction **reducer()** prend en entrée un ensemble de paires **<clé, liste de valeur>** produites par la fonction **map()**, et les traite pour produire un ensemble de paires **<clé, valeur>** en sortie.
- Cette fonction est appliquée de manière parallèle à chaque ensemble de paires de données associées à une même clé, ce qui permet un traitement efficace des données sur un grand nombre de noeuds.
- Le résultat final produit par la fonction **reducer()** est ensuite utilisé comme sortie du processus MapReduce.
- La fonction **reducer()** permet de regrouper et de traiter les données intermédiaires produites par la fonction **map()** en parallèle, ce qui est essentiel pour le traitement efficace des gros volumes de données dans un environnement distribué comme Hadoop.

Les avantages du MapReduce:



Les avantages du MapReduce (2):

- **Extensibilité:** Mapreduce permet de stocker de larges ensembles de données sous une forme distribuée entre de multiples serveurs, ce qui rend possible le traitement parallèle et le rend hautement extensible.
- **Traitement parallèle:** Les tâches Map et Reduce sont séparées, et l'exécution parallèle réduit le temps d'exécution dans son ensemble.
- **Flexibilité:** MapReduce peut s'adapter à des milliers de nœuds grâce à ses systèmes de fichiers distribués et à sa capacité à exécuter des processus à proximité des données au lieu de déplacer les données elles-mêmes.
- **Tolérance aux pannes:** MapReduce a la capacité de reconnaître rapidement les défauts qui se produisent, puis appliquer une solution rapide et automatique de récupération, ce qui en fait un changeur de jeu quand il vient à grand traitement de données.

Des exemples concrets d'utilisation de MapReduce:

- **Analyse de logs:** MapReduce est utilisé pour analyser de grands ensembles de logs, par exemple pour suivre l'évolution de la population d'un site web dans différentes régions géographiques.
- **Détection de fraude:** Les entreprises du secteur financier utilisent MapReduce pour détecter les schémas de fraude ou pour analyser les transactions afin d'identifier les modèles suspects.
- **Analyse de données météorologiques:** MapReduce peut être utilisé pour analyser de grandes quantités de données météorologiques et extraire des informations telles que les températures maximales pour chaque ville à partir de multiples fichiers de données.
- **Optimisation de performances:** MapReduce peut être utilisé pour optimiser les performances des phases de mapping, de shuffling et de tri, par exemple dans le traitement de volumes de données liés à des systèmes de recommandation ou d'analyse de données.

Conclusion:

En résumé, MapReduce est un modèle de programmation qui permet de traiter de grands volumes de données en parallèle, ce qui le rend adapté au contexte du Big Data. Il est utilisé dans de nombreux domaines, tels que l'analyse de logs, la détection de fraude, l'analyse de données météorologiques, et l'optimisation de performances. Les avantages de MapReduce incluent sa flexibilité, son traitement parallèle et sa tolérance aux pannes. MapReduce est également une solution rentable pour les entreprises, car il peut être exécuté sur des clusters peu coûteux. En somme, MapReduce est un outil puissant pour le traitement et l'analyse de gros volumes de données dans divers domaines, et il est devenu un favori des professionnels du Big Data dans le monde entier.



“Merci de votre attention”

